


- Büyük boyutlu diziler içerisinde küçük dizilerin hizalanması önemli ve zaman alıcı bir problemdir.
- Bu amaçla sezgisel metotlar ve önceden bu verileri indekslenmiş veritabanları kullanılmaktadır.
- Veritabanı benzerlik arama yöntemlerini aşağıdaki başlıklar altında inceleyebiliriz;
- Tek Sekans Sorguları
- Profil Aramaları
- Pozisyona Özel Sorgu Matrisleri
- İteratif Hizalama
- Örüntü Veritabanlarında Örüntü Arama

Tek Sekans Sorguları

- BLAST
- Bunların başında BLAST veritabanı ve dizi sorgulama aracı gelmektedir.
- Bu aracın temel fikri iyi hizalamaların, kısa ancak birebir eşleşmeler içereceğidir.
- Bu amaçla DNA için 11 elemanlı, proteinler için 3 elemanlı kısa diziler ve konumları pek çok canlı türü için tüm genom boyunca önceden taranarak indekslenmiştir.
- Bu indeksler ile önce arama için girilen dizilerden alınan 11 veya 3 elemanlı bölümlerin tam eşleşmeleri (ön tanımlı olarak BLOSUM62 ye göre) belirlenir sonrasında ise bu eşleşmeler iki yöne doğru genişletilerek en iyi hizalamalar bulunur.



BLAST

- BLAST veritabanı indeksleme temelde işlemini barındırdığı sekansları 11 li veya 3 lu kümelerle ayırarak yapar.
- Bu şekilde sorgu için girilen sekans bu kümelerden hangilerine uyuyorsa hizalama sadece bu kümeler için yapılır.



BLAST

- Bahsi geçen genişleme hizalama skoru belirlenen bir minimum S skoruna erişinceye veya negatife düşünceye kadar devam eder.
- Bu şekilde bulunan en yüksek skora sahip eşlerin (High Score Pairs – HSP) birbirlerine olan uzaklıkları belirli bir A uzaklığından az ise birleştirilerek yeni bir hedef eşleşme oluşturulabilir.



BLAST

- Son olarak hesaplanan hizalama skorunun istatistiksel anlamlılığı hesaplanır.
- Detaylarını ileride paylaşacağımız bu istatistiksel anlamlılık e skoru olarak ifade edilir ve bulunana tesadüfi olarak benzer kaç başka gen/protein olduğunu ifade eder.
- Genelde 1/1000 ve daha altında e skoru olan hizalamalar anlamlı kabul edilir.
- BLAST ender görülen yüksek anlamlılıktaki örüntüleri arar.
- FASTA'dan daha hızlıdır.
- Diğer sezgisel yöntemler gibi optimal çözümü garanti etmez.
- NCBI ve pek çok farklı sitede yer aldığından oldukça popülerdir.

FASTA

- İnceleyeceğimiz bir diğer sezgisel metot FASTA dır.
 - FASTA word veya k-tups olarak adlandırılan kısa dizilerin yerel eşleşmelerini kullanarak daha uzun eşleşmeleri bulmaktadır. Algoritma şu şekilde işler;
- 1- Proteinler için 1-2 aminoasitlik, DNA için 4-6 baz uzunluğu seçilir.
 - 2- Seçilen bu uzunluğa denk eşleşmelerin pozisyonları tespit edilir.
- Bu eşleşmeler doğru veya yanlış eşleşmelerden oluşabilir ancak boşluk içeremez. Ancak doğru eşleşmelerin arasında görülen yanlış eşleşmeler negatif skor alırlar. Pozisyonlar her bir amino asitin yada bazın kıyaslanacak dizilerdeki pozisyonlarının farkının alınması ile bulunur. Örneğin aşağıdaki dizide c,s,p aminoasitlerinin pozisyon farkları -5 sonucunu verdiği için bunlar ardışık bir eşleşme oluştururlar.

FASTA

```

position 1 2 3 4 5 6 7 8 9 10 11
protein 1 n c s p t a . . . .
protein 2 . . . . . a c s p r k

```

amino acid	position in protein A	position in protein B	offset pos A - posB
a	6	6	0
c	2	7	-5
k	-	11	-
n	1	-	-
p	4	9	-5
r	-	10	-
s	3	8	-5
t	5	-	-

Note the common offset for the 3 amino acids c,s and p
A possible alignment is thus quickly found -


```

protein 1 n c s p t a
          | | |
protein 2 . . . . . a c s p r k

```


FASTA

- 3- Oluşturulan bu eşleşmelerden en yüksek skora sahip 10 tanesi seçilir. Seçilen çapraz biçimdeki pozisyonlar tekrar taranarak proteinler için PAM250 ye göre ve DNA için belirlenen skorlama kriterlerine göre yeniden skorlanır.
- En iyi skora ulaşmak için bölgelerin uçları budanır.
- Geri kalanlar aşağıdaki dot plot matrix de görüldüğü biçimde elenir.



FASTA

4- Sadece bu 10 eşleşmenin bulunduğu bölge birleştirilir ve aynı dinamik programlamada olduğu gibi skorlanır.




FASTA

5- Dinamik programlamada gördüğümüz biçimde skorlanan bölge geriye doğru takip edilerek optimal dizi bulunur.

- Sonuç olarak bu algorithmda yapılan işlem sezgisel olarak hizalamanın yapılacağı yolun hangi bölgede olduğunu tespit etmek ve dolayısı ile dinamik programlama ile olan hizalamayı daha küçük bir bölgede uygulamaktır.
- BLAST dan farklı olarak kesin (exact) eşleşmeler ile başlar.
- Doğruluğu ve algoritmik karmaşıklığı BLAST ile benzerdir.
- Bu yöntemde k-tup uzunluğu arttıkça gürültü azalır ancak bu da sistemin yavaşlaması sonucunu doğurur.
- Dolayısı ile k-tup uzunluğu hız ve hassasiyet arasında bir alış-veriş durumu yaratır.
- Diğer sezgisel yöntemler gibi optimal çözümü garanti etmez.

BLAT

- Örtüşmeyen 11-baz veya 4-aa lik dizileri tüm genom için oluşturulmuş bir indeksini hafızasında tutar.
- Bu indeksi kullanarak 25 bazdan büyük en az %95 üzeri benzerlik içeren DNA dizilerini veya 20 aa dan büyük en az %80 benzerlik protein dizileri bulmayı sağlar.



BLAT

- Yapılan hizalamalar çok kısa ise veya düşük benzerlik içeriyorsa bu dizileri bulamayabilir.
- Özellikle uzun intron bölgelerini bulmada etkindir.
- BLAT, BLAST a oranla çok çok daha hızlıdır.
- Ancak bu hızın bedeli düşük benzerlikteki homologları eşleştirememesidir.
- BLAT Fasta formatında verilen çok sayıda diziyi aynı sorgulayabilir ve UCSC genome gezgininin içinde entegre olarak yer alır.
- mRNA veya proteinlerin genomik pozisyonlarının bulunması, exon yapısının belirlenmesi, Kodlayan bölgelerin gösterilmesi, bir gen ailesinin üyelerinin aranması, diğer türlerde insan homologlarının bulunması gibi pek çok farklı işlevi vardır.

SSEARCH

- Tüm dizi hizalama yöntemi ile veritabanlarını arar.
- Sorgu için optimal sonuçları bulur.
- Birbirine uzak dizileri de bulma kabiliyetine sahiptir.
- Ancak FASTA veya BLAST dan yaklaşık 50 kat daha yavaş çalışır.

Pozisyona Özel Skorlama

- Daha önce eşli hizalamadan bahsetmiştik.
- Diğer taraftan eşli hizalamanın çözemediği pek çok problem vardır.
- Bunlardan ilki bir sekansın hangi protein ailesine ait olduğunun bulunması problemidir.
- Protein aileleri yakın işlevlere sahip protein homologlarından oluşur.
- Örneğin oksijenin bağlanması ve taşınmasında rol alan Globin proteininin pek çok türü vardır ve bunlar Globin protein ailesini adı altında gruplanırlar.
- Yeni bir sekansın bir protein ailesine ait olup olmadığını bulma problemi sıkça karşılaşılan bir problemdir.
- Bu şekilde bir proteinin fonksiyonuna ve 3 boyutlu yapısına dair tahminde bulunabiliriz.

Pozisyona Özel Skorlama

- Ancak pek çok farklı sekansdan oluşan birden çok proteine karşı tek bir proteini nasıl hizalayabiliriz ? Aşağıdaki örneğe bakalım;

		-	A	G	G	C	T	A	T	C	A	C	C	T	G
T	A	G	-	C	T	A	C	C	A	-	-	-	-	G	
C	A	G	-	C	T	A	C	C	A	-	-	-	-	G	
C	A	G	-	C	T	A	T	C	A	C	-	-	G	G	
C	A	G	-	C	T	A	T	C	G	C	-	-	G	G	
A			1				1		.8						
C	.6			1			.4	1	.6	.2					
G			1	.2			.2			.4	1				
T	.2				1		.6			.2					
-	.2		.8						.4	.8	.4				

Pozisyona Özel Skorlama

- Belirli bir pozisyonda birden çok çeşit baz veya aminoasit olabileceğine göre, bu pozisyondaki durumu, belirli bir bazın varlığı veya yokluğu ile değil, söz konusu bazın o pozisyonda bulunma olasılığı ile temsil edebiliriz.
- Bu şekilde eşleşme skorunu, ilgili bazın eşleşme pozisyonunda bulunma olasılığı ile ağırlıklandırarak kullanabiliriz.
- Örneğin bir pozisyonda %80 oranda A ve %20 oranda C bulunuyorsa ve bu pozisyonda başka bir diziden A ile bir eşleşme yapılacaksa, toplam skor = (doğru eşleşme skoru x 0.8) + (yanlış eşleşme skoru x 0.2) olacaktır.
- Bu şekilde yapılan aramalar Profil ile Hizalama Araması olarak adlandırılır.

Pozisyona Özel Skoring

- Proteinlerin hizalanması için, kullandığımız matrisleri de, bu şekilde modifiye edebiliriz.
- Bu modifiye edilmiş matrislere, pozisyona özel skoring matrisi (position specific scoring matrices – PSSM), adı verilir.
- Bu matrisler verilen dizilerden oluşturulabileceği gibi, veritabanları kullanılarak da oluşturulabilirler.
- Bu matrisler aminoasitlerin standart hizlama skorları ile söz konusu pozisyonda bulunma olasılıkları çarpılması ve bu çarpımların toplanması ile oluşturulur.
- Örneğin, N sayıda sekansın çoklu hizalaması için, u pozisyonundaki bir b aminoasitinin a aminoasiti ile eşleşmesini tanımlayan formül aşağıdaki biçimde olacaktır.


Pozisyona Özel Skoring

- Profil ile Hizalama Araması ve PSSM arasındaki temel fark Profil ile Hizalama Aramasında, profil boşluklar içerecek biçimde hazırlanırken, PSSM matrislerin boşluksuz bölgeler kullanılarak hazırlanıyor olmasıdır.
- Bundan dolayı PSSM aramalarında aynı uzunluktaki hizalanmamış diziler aranır.

$$f_{u,b} = \frac{n_{u,b}}{N} \quad m_{u,a} = \sum_{\text{residue types } b} f_{u,b} s_{a,b}$$

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Tek bir dizinin birden çok diziye karşı hizlanması probleminden bahsettik. Şimdiki problemimiz ise birden çok dizinin tamamının birbirine karşı hizlanması olacak.



Wikipedia. (2012, June 25). Retrieved from http://en.wikipedia.org/wiki/Multiple_sequence_alignment

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Problemi en basit haliyle ikiden fazla dizinin hizalanması olarak tanımlayabiliriz.
- Temel olarak bu işlem için Needleman-Wunsch algoritmasını uygulamak mümkündür.
- Ancak bu uygulama, hesaplama açısından çok yüksek, işlemci ve hafıza gerektireceğinden verimsiz olacaktır.
- Bundan dolayı, çoklu dizi hizalama algoritmalarının çoğu sezgisel yöntemlerle çalışır.

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)


- Çoklu hizalamanın kullanım alanlarını;
- Filogenetik Ağaç Oluşturma
- Proteinlerin ikincil ve üçüncül yapılarının tahmini
- Fonksiyon Tahmini
- Primer Tasarımı
- Tam Genom Sekans Analizi
- olarak özetleyebiliriz.

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Çoklu dizi hizalama metotlarını ise aşağıdaki biçimde gruplayabiliriz.
- Dinamik Programlama
- Sezgisel Metotlar
 - Progresif Global Hizalama
 - İteratif Global Hizalama
- Meta-Yöntemler (Meta-Methods)
- Şablon Temelli Yöntemler (Template Based Methods)
- Sekanslarla Yerelleştirilmiş Hizalamalar (Localized Alignments within sequences)
- İstatistiksel ve Olasılıksal Yöntemler


Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Bunlardan ilki olan dinamik programlamanın çoklu hizalama için yüksek işlemci ve hafıza gereksiniminden bahsetmiştik.
- Aşağıda üç dizi için oluşturulmuş bir matris yapısı görülüyor.



Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Bunu biraz daha açalım.
- İki diziye hizalarken, iki boyutlu bir matris yeterli olurken, üç dizi için, üç boyutlu bir matris kullanmamız gerekir skora için.
- Bu durumda her adımda 3 yerine 7 farklı komşu hücreden, hedef hücreye ulaşmak için skor hesaplamalıyız.




Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Dolayısı ile, n uzunlukdaki 3 dizi için gereken zaman $O(7n^3)$ olacaktır.
- Bunu genelleştirirsek k sekans için $O(2^k - 1 \cdot n^k)$ olacaktır.
- Dolayısı ile üstel olarak artan bu yapı sadece az sayıda (en çok 20) veya çok kısa diziler için verimli olabilir.
- Dolayısı ile arama alanını küçültmek yerinde olacaktır.

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Örneğin aşağıda görülen gri alan ve üç renki projeksiyonu bize 3 boyutlu bir matris içinde sınırlandırılmış arama alanlarını göstermektedir.
- FASTA da olduğu gibi bu sadece bu sınırlandırılmış alan üzerinde skorelama ve geriye doğru takip yaparak, gerekli hesaplama ve hafıza kaynağını büyük ölçüde düşürebiliriz.



Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Clustal W algoritması bu şekilde çalışan progresif yöntemlere bir örnektir.
- Sezgisel olarak çalışan bu algoritma öncelikle dizi benzerliklerine bağlı olarak bir rehber ağaç (guidance tree) oluşturur.
- Bunun için hizalanacak n sayıda sekans varsa $n(n+1)/2$ tane eşli hizalama yapar (sadece maksimum hizalam skorunun hesaplanması yeterlidir).
- Sonra ise bu ağaçta en yakın komşulardan (en çok benzeyen dizilerden) başlayarak dizileri ikiye ikiye hizalar ve bu şekilde bütün diziler bitene kadar devam eder.

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Binlerce diziyi bu şekilde hizalamak mümkündür.
- Ancak açgözlü (greedy) bir algoritma olduğu için sürekli olarak en yüksek benzerlik skoruna sahip dizileri eşleştirerek hizalayacaktır.
- Bu sebepten dolayı en iyi çözümü bulabileceğinin garantisi yoktur.
- Özellikle birbirine uzak dizilerin hizalanması konusunda zayıftır.

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Aşağıda rehber ağacı oluşturulduktan sonra bu yöntemin adım adım nasıl işlediği gösterilmiştir.

Progressive Alignment - step 2

gctcgatacgcgatgcgactagcta
gctcgatacaagacgatgcagcta
gctcgatacacgatgcactagcta
gctcgatacacgatgcagagcga
ctcgaacgatgcgatgcactagct

gctcgatacacgatgactagcta
gctcgatacacgatgacgagcga

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Aşağıda rehber ağacı oluşturulduktan sonra bu yöntemin adım adım nasıl işlediği gösterilmiştir.


Progressive Alignment - final step

gctcgatacgcatacgcgtgactagcta
gctcgatacaagacgatgac-agcta
gctcgatacacga---tgactagcta
gctcgatacacga---tgacgagcga
+
ctcgaacgcatacgcgtgactagct

gctcgatcacgatacgatgactagcta
gctcgatacaagacgatgac-agcta
gctcgatacacga---tgactagcta
gctcgatacacga---tgacgagcga
-ctcga-acgatacgatgactagct-


Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Peki bu işlem sırasında bir yada birden çok dizi birbirleri ile nasıl hizalayabiliriz ?
- İkili hizalamalar ile bir konsensüs oluşturmak her zaman mümkün olmayabilir.
- Örneğin aşağıdaki örnekte ilk durumda bir konsensüs oluşabilirken, ikinci durumda bu mümkün olmuyor.




Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- İlk kısımda gördüğümüz profil yapısını bu durum içinde kullanabiliriz.
- Bir dizi bir profil ile hizalayabileceğimiz gibi aynı mantığı kullanarak, iki profili de hizalayabiliriz.



Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Sonuç olarak Clustal W yöntemini aşağıdaki biçimde özetleyebiliriz.



Mount, W. David. (2004). *Bioinformatics sequence and genome analysis*. (2 ed., p. 183). New York: Cold Spring Harbor Laboratory Press.

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Bu işlem sırasında tüm sekansların öneminin eşit olduğunu varsaymaktayız.
- Örneğin bir insan çalışması sırasında insana daha yakın olan türlerdeki protein sekansları bizim için daha önemli olabilir.
- Diğer taraftan sekanslardaki belirli bölgeler de bizim için daha yüksek önem arz edebilir.

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Buradan yola çıkılarak Clustal W üzerinde bazı iyileştirmeler yapılabilir.
- Dizilere farklı ağırlıklar vermek
- Değişken skorlama matrisleri kullanmak
- Rezidü spesifik boşluk cezaları kullanmak
- Proteinlerin hidrofilik dış bölgeleri için daha düşük boşluk cezası uygulayarak fonksiyonel iç bölgelerin daha az boşlukla hizalanmasını sağlamak.
- İlk önce yapılan hizalamalarda daha düşük boşluk cezası uygulayarak sonraki hizalamalar için hareket serbestliği kazanmak.

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Clustal ailesi bütün bu iyileştirmelere rağmen bazı problemlere sahiptir.
- Kısa yerel benzerliklerin hizalanması, büyük insersiyonlar ve tekrar dizilerinin hizlanması bu algoritmanın başarısını düşürmektedir.
- Aşağıda daha önce bahsettiğimiz çoklu sekans hizalama yöntemlerinin en çok kullanılan gerçekleştirmeleri bulunuyor.

Widely Used MSA Algorithms

- **Heuristic Methods:**
- **Progressive Methods**
 - Substitution Matrix (Clustal W)
 - **Consistency (T-Coffee)**
- Iterative Methods (MUSCLE)
- Meta-Methods (M-Coffee)
- Template Based Methods
 - Structure (EXPRESSO, T-LARA)
 - Profiles (PRALINE, PROMALS)

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- İteratif Yöntemler
- Progresif yöntemlerde başlangıçta yapılan hatalar, tüm çoklu dizlemeye yansır.
- İteratif yöntemlerde ise bu hatalar başlangıç dizilerinin tekrarlanan hizalamaları ile düzeltilir.
- Bu yöntemlerden en yaygın olanları, PRRN/PRRP , CHAOS/DIALIGN ve MUSCLE'dır.

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Meta-Yöntemler
- Çoklu hizalamada bir diğer alternatif ise bu noktaya kadar gördüğümüz birçok yaklaşımı entegre eden, meta-yöntemlerdir.
- Bunlardan en yaygın olanı M-Coffee, yaygın metotlar ile (ClustalW, MAFFT, MUSCLE....) birincil kütüphaneleri oluşturur ve sonrasında, T-Coffee ile bu kütüphaneleri birleştirerek, çoklu dizi hizalama işlemini gerçekleştirir.

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Meta-Yöntemler
- Çoklu hizalamada bir diğer alternatif ise bu noktaya kadar gördüğümüz birçok yaklaşımı entegre eden, meta-yöntemlerdir.
- Bunlardan en yaygın olanı M-Coffee, yaygın metotlar ile (ClustalW, MAFFT, MUSCLE....) birincil kütüphaneleri oluşturur ve sonrasında, T-Coffee ile bu kütüphaneleri birleştirerek, çoklu dizi hizalama işlemini gerçekleştirir.

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- İstatistiksel çoklu hizama yöntemleri


Statistical Methods for Aiding Alignment

- Expectation Maximization Algorithm
- The Gibbs Sampler
- Hidden Markov Models
- Multiple EM For Motif Elicitation (MEME)

Example:

Multiple EM for Motif Elicitation (MEME)
• <http://meme.sdsc.edu/>

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)



Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Günümüzde çoklu dizi hizalamanın halen problemleri bulunmaktadır. Bunlar;
- Sayısal Olarak
- Küçük veri setleri dışında tam bir hizalamanın mümkün olmaması
- Hata payı bulunan çok sayıda sezgisel algoritmanın geliştirilmiş olması ve bunlar arasında seçim yapmanın güçlüğü
- Biyolojik Olarak
- Yapılan hizalamaların biyolojik doğruluğunun ölçülmesi için kesin bir ölçüm yöntemi bulunmaması
- Protein yapıları ile yapılan hizalama doğruluk ölçümlerinin ancak çok az sayıda sekans için mümkün olması
- Hesaplama kolaylığından dolayı genellikle sekans benzerliğinin bir ölçü olarak kullanılması
- olarak tanımlanabilir.

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Çoklu Hizalama Yöntemlerinin Doğrulanması ve Değerlendirilmesi
- Yukarıda çoklu hizlama algoritmalarının değerlendirilmesi için en iyi yöntemin üç boyutlu yapı benzerliği olduğundan bahsetmiştik.
- Bu yapılar temel alınarak çoklu hizalamaların doğrulanması için referans veri kümeleri oluşturulmuştur.
- Büyük veri kümelerinin hizalanması için de bu veri setlerinden faydalanılabilir.
- Üç boyutlu yapısı bilinen proteinlere ait sekanslar referans olarak kullanılarak çoklu hizalama yapılabilir.
- Ancak bazen bu yöntem yerine profil bazlı hizalama daha iyi çalışmaktadır.

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

3. İteratif Yöntemler

- Bir sorgu sekansı için benzer sekansların iteratif olarak aranması işlemdir. Bu yöntemde;
- Başlangıç olarak boşluklu bir çoklu hizalama yapılır.
- Sonrasında bu geçici hizalamalar kullanılarak bir skorlama matrisi oluşturulur.
- Olası eklemeler için yeni aramalar yapılır.
- Bu şekilde iterasyonlar devam eder.

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Daha önce incelediğimiz BLAST algoritmasının pek çok iteratif biçimi bulunmaktadır.
- Bunların başında,
- PSI-BLAST
- PHI-BLAST
- RPS-BLAST
- gelmektedir.
- Bu üç algoritma da protein benzerliklerinin bulunması açısından oldukça güçlü algoritmalar.

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- PSI-BLAST
- PSI-BLAST (Position Specific Iterated – BLAST) özellikle birbirine (evrimsel olarak) uzak proteinleri yüksek hassasiyet ile tespit edebilir.
- Proteinlerin fonksiyonel ilişkilerine dair fikir verir.
- İyi tasarlanmış istatistiksel bir altyapısı vardır.
- BLAST yöntemlerine dayanan bu metodun kullanımı da kolaydır.
- Metot aşağıdaki adımlardan oluşur;
- Standart blastp algoritması geliştirilir
- En yüksek skora sahip hizalamalar çoklu hizalama oluşturmak için kullanılır.
- Yapılan çoklu hizalama kullanılarak bir PSSM oluşturulur.
- Bu PSSM de korunmuş bölgeler yüksek skor alırken, az korunmuş bölgeler düşük skor alır.
- Yeni oluşturulan PSSM kullanılarak yeni bir arama yapılır.
- 2,3,4 numaralı adımlar sonuç yeterince yakınsayana kadar devam ettirilir.

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- PHI-BLAST
- PHI-BLAST (Pattern Hit Initiated – BLAST), PSI-BLAST ile benzer biçimde çalışır.
- Ancak ilk aramada sekans bilgisinin yanında motif örüntüsünü de kullanır arama için.
- Bu işlemin sonucunda, sorgulanan dizinin içinde bulunduğu motiflere benzeyen motiflerin çevresinde yer alan yeni dizileri keşfeder.
- İlk aramadan sonra PHI-BLAST, PSI-BLAST ile aynı biçimde çalışır ve oldukça spesifik sonuçlar üretir.
- Bu şekilde PHI-BLAST ile protein sorgularında belirli örüntüleri aramak mümkün olur.

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)


- Örüntü Veritabanlarında Örüntü Arama
- Bu yöntemde arama sekans veritabanları yerine örüntü veritabanlarında (Prosite / Interpro / pFAM / CDD gibi) yapılır.
- Aranacak örüntü, tek bir sekans olabileceği gibi, bir skorlama matrisi veya bir profil de olabilir.
- Bu aramada çıktı bir sekans örüntü listesi olarak geri döndürülür.

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Sonuç
- Bütün bu arama yöntemleri arasında protein düzeyinde yapılacak aramalar öncelikle tercih edilmelidir.
- Çünkü sonuçta üretilen ürün protein olduğu için bu seviyede bulunan benzerlikler daha doğru sonuç üretecek ve daha az gürültü içerecektir.

Çoklu Dizi Hizalama (Multiple Sequence Alignment – MSA)

- Aşağıdaki şekilde veritabanı sorgulamalarında kullanılabilecek bir karar algoritması verilmiştir.



Mount, W. David (2004). *Bioinformatics: Sequence and Genome Analysis* (2 ed., Vol.1, p.239), New York, Cold Spring Harbor Laboratory Press